

Xây dựng Hệ thống Khuyến nghị Y tế Tự động dựa trên Kiến trúc Retrieval-Augmented Generation và Mô hình Ngôn ngữ Lớn Tiếng Việt

Nguyễn Vũ Anh Khoa, Hồ Nguyễn Thiên Vũ, Nguyễn Phi Long, Phạm Hồng Trà
Trường Đại học Công nghệ Thông Tin - ĐHQG TP HCM
{22520684, 22521689, 22520818, 22521495}@gm.uit.edu.vn

Tóm tắt

Trong kỷ nguyên số hóa, sự giao thoa giữa y tế và công nghệ thông tin đã và đang tạo ra những thay đổi mang tính cách mạng trong cách con người tiếp cận dịch vụ chăm sóc sức khỏe. Sự phát triển bùng nổ của Trí tuệ nhân tạo (AI), đặc biệt là các Mô hình Ngôn ngữ Lớn (Large Language Models - LLMs), đã mở ra những hướng đi mới cho việc tự động hóa tư vấn và phân loại thông tin y khoa. Tuy nhiên, đi kèm với tiềm năng to lớn đó là những thách thức kỹ thuật không nhỏ liên quan đến độ tin cậy và tính chính xác của thông tin. Đề tài này được thực hiện nhằm giải quyết bài toán cốt lõi về sự thiếu hụt một hệ thống tư vấn y tế tự động, thông minh, hỗ trợ tiếng Việt và có khả năng kiểm soát rủi ro thông tin sai lệch.

1. Giới thiệu

1.1. Bối cảnh nghiên cứu

Sự gia tăng nhu cầu tra cứu thông tin y tế trực tuyến

Trong những năm gần đây, hành vi tìm kiếm thông tin sức khỏe trên Internet đã trở thành một thói quen phổ biến toàn cầu. Theo các khảo sát xã hội học về hành vi người dùng, một tỷ lệ lớn người dân có xu hướng tham khảo "Bác sĩ Google" hoặc các diễn đàn trực tuyến trước khi quyết định đến cơ sở y tế. Sự chuyển dịch này phản ánh nhu cầu cấp thiết về việc tiếp cận thông tin y tế tức thời, chi phí thấp và tiện lợi [1]. Tại Việt Nam, với áp lực quá tải tại các bệnh viện tuyến đầu, nhu cầu này càng trở nên bức thiết hơn bao giờ hết. Người dân cần một công cụ sơ cấp để định hướng chuyên khoa, giúp họ tiết kiệm thời gian và giảm tải cho hệ thống y tế công cộng.

Hạn chế của các mô hình LLM hiện tại: Vấn đề "Ảo giác"

Trong khoa học máy tính, ảo giác của mô hình ngôn ngữ được định nghĩa là hiện tượng mô hình sinh ra các nội dung có vẻ logic, trôi chảy về mặt ngữ pháp nhưng lại hoàn toàn sai lệch về mặt thực tế hoặc

không trung thực với dữ liệu nguồn [2]. Điều này bắt nguồn từ bản chất hoạt động của LLM: chúng là các mô hình xác suất, dự đoán từ tiếp theo dựa trên chuỗi từ trước đó mà không thực sự "hiểu" kiến thức hay có khả năng kiểm chứng sự thật. Trong bối cảnh y khoa, một lời khuyên sai lệch (ví dụ: gợi ý liều lượng thuốc sai, hoặc bịa đặt một phương pháp điều trị không tồn tại) có thể dẫn đến hậu quả nghiêm trọng cho sức khỏe người dùng [3].

Hơn nữa, đa số các LLM phổ biến hiện nay được huấn luyện chủ yếu trên dữ liệu tiếng Anh. Khi hoạt động với tiếng Việt, đặc biệt là các thuật ngữ y khoa chuyên ngành, mô hình thường gặp khó khăn trong việc nắm bắt ngữ cảnh văn hóa và đặc thù ngôn ngữ địa phương, dẫn đến việc tư vấn thiếu chính xác hoặc diễn đạt không tự nhiên [4]. Do đó, việc phụ thuộc hoàn toàn vào kiến thức tham số (parametric knowledge) có sẵn trong các mô hình pre-trained là không đủ an toàn cho các ứng dụng y tế. Đây là động lực chính thúc đẩy chúng tôi thực hiện dự án này, nhằm tìm kiếm một giải pháp kỹ thuật có khả năng "neo giữ" (grounding) câu trả lời của AI vào các nguồn dữ liệu y học uy tín.

1.2. Mục tiêu đề tài

Dựa trên những thách thức đã phân tích, dự án đặt ra mục tiêu cốt lõi là xây dựng và triển khai thử nghiệm một hệ thống khuyến nghị y tế tự động (Healthcare Recommendation System), tích hợp kỹ thuật **Tạo sinh Tăng cường Truy xuất (Retrieval-Augmented Generation - RAG)**. Mục tiêu của đề tài được cụ thể hóa qua các khía cạnh sau:

Xây dựng cơ chế hiểu triệu chứng từ ngôn ngữ tự nhiên

Hệ thống được thiết kế để nhận đầu vào là các mô tả triệu chứng dưới dạng văn bản tự do của người dùng. Thay vì bắt người dùng phải chọn các từ khóa cứng nhắc, hệ thống cho phép họ diễn đạt tình trạng sức khỏe theo ngôn ngữ đời thường. Nhiệm vụ của hệ thống là chuyển đổi các mô tả phi cấu trúc này thành các biểu diễn vector (embeddings) để máy tính có thể hiểu và xử lý.

Định hướng chuyên khoa và cung cấp lời khuyên tham khảo

Khác với các chatbot thông thường chỉ trò chuyện xã giao, đầu ra của hệ thống hướng tới hai giá trị cụ thể:

1. **Gợi ý chuyên khoa:** Dựa trên triệu chứng, hệ thống phân loại và đề xuất chuyên khoa phù hợp (ví dụ: Nhi khoa, Da liễu, Hô hấp) để người dùng có hướng đi khám đúng đắn.
2. **Lời khuyên y tế tham khảo:** Tổng hợp thông tin từ cơ sở dữ liệu để đưa ra các lời khuyên về chế độ sinh hoạt, cách xử lý sơ cứu hoặc các cảnh báo cần thiết.

Kiểm soát chất lượng và tính trung thực

Một mục tiêu quan trọng của đề tài là giảm thiểu tối đa hiện tượng ảo giác. Chúng tôi không chỉ tập trung vào việc mô hình trả lời "hay", mà quan trọng hơn là trả lời "đúng" dựa trên dữ liệu đã được kiểm chứng. Hệ thống phải có khả năng trích xuất chính xác các đoạn văn bản liên quan từ kho dữ liệu y tế (Retrieval) và sử dụng chúng làm ngữ cảnh để sinh câu trả lời (Generation), thay vì để mô hình tự "sáng tác".

Dự án xác định rõ giới hạn của hệ thống là công cụ hỗ trợ thông tin, mang tính chất khuyến nghị và tham khảo. Hệ thống không đưa ra chẩn đoán bệnh lý cuối cùng và không thay thế vai trò của bác sĩ chuyên khoa. Mọi lời khuyên đều đi kèm với khuyến cáo người dùng cần tham vấn ý kiến chuyên gia y tế [5].

1.3. Phạm vi

Để đảm bảo tính khả thi và độ sâu kỹ thuật, đề tài giới hạn phạm vi trong các yếu tố sau:

Dữ liệu y tế tiếng Việt

Dự án tập trung xử lý và khai thác nguồn dữ liệu y văn hoàn toàn bằng tiếng Việt. Dữ liệu này bao gồm hai thành phần chính:

1. **Kho bài viết y học:** Được thu thập từ các cổng thông tin y tế uy tín tại Việt Nam (như dữ liệu từ Vinmec, Long Châu, Bệnh viện Tâm Anh...). Việc sử dụng dữ liệu nội địa đảm bảo các lời khuyên phù hợp với đặc thù dịch tễ, khí hậu và cơ sở vật chất y tế tại Việt Nam.
2. **Bộ dữ liệu Hỏi - Đáp (QA):** Các cặp câu hỏi và trả lời mẫu giữa bệnh nhân và bác sĩ, giúp mô hình học được văn phong tư vấn và cách giải quyết vấn đề thực tế.
3. Quá trình tiền xử lý dữ liệu (làm sạch, ẩn danh thông tin cá nhân) cũng nằm trong phạm vi thực hiện của đề tài nhằm đảm bảo tuân thủ các quy định về đạo đức dữ liệu [6].

Các mô hình ngôn ngữ hỗ trợ tiếng Việt

Về mặt công nghệ, đề tài không xây dựng một LLM mới từ đầu (pre-training from scratch) do giới hạn về tài nguyên tính toán, mà tập trung vào việc ứng dụng và tinh chỉnh các mô hình mã nguồn mở tiên tiến đã hỗ trợ tốt tiếng Việt.

Đối với tác vụ truy xuất thông tin (Retriever), đề tài sử dụng các mô hình thuộc họ BERT đã được huấn

luyện trên ngữ liệu tiếng Việt lớn, điển hình là PhoBERT. Đây là mô hình nền tảng giúp hiểu sâu sắc ngữ nghĩa tiếng Việt [7].

Đối với tác vụ sinh văn bản (Generator), đề tài khám phá và so sánh hiệu năng của các LLM thể hệ mới như PhoGPT hoặc Vistral. Các mô hình này được lựa chọn dựa trên tiêu chí về khả năng hiểu chỉ dẫn (instruction following) và khả năng sinh văn bản tiếng Việt tự nhiên, mạch lạc.

Phạm vi đề tài cũng bao gồm việc thiết kế kiến trúc RAG, tối ưu hóa cơ sở dữ liệu vector để tìm kiếm nhanh, và xây dựng giao diện tương tác cơ bản để đánh giá hiệu quả thực nghiệm. Các vấn đề liên quan đến chẩn đoán hình ảnh (X-quang, MRI) hay dữ liệu gen nằm ngoài phạm vi của dự án này.

2. Cơ sở dữ liệu


Chất lượng của một hệ thống trí tuệ nhân tạo, đặc biệt là trong lĩnh vực y tế, phụ thuộc tiên quyết vào chất lượng của dữ liệu đầu vào. Đối với kiến trúc Retrieval-Augmented Generation (RAG), cơ sở dữ liệu không chỉ đóng vai trò là tài liệu huấn luyện (training data) mà còn là kho tri thức tham chiếu (knowledge base) để hệ thống truy xuất thông tin theo thời gian thực. Trong phạm vi đề tài này, chúng tôi đã xây dựng quy trình thu thập và xử lý dữ liệu nghiêm ngặt nhằm đảm bảo tính chính xác, độ bao phủ các chuyên khoa và tuân thủ các chuẩn mực về đạo đức dữ liệu.

2.1. Thu thập dữ liệu

Để giải quyết bài toán tư vấn y tế tổng quát, chúng tôi xác định chiến lược dữ liệu cần sự kết hợp giữa kiến thức chuyên sâu (từ các bài viết y khoa) và ngữ cảnh giao tiếp thực tế (từ các cặp Hỏi - Đáp). Tổng cộng, kho dữ liệu của dự án bao gồm hai thành phần chính:

1. Dữ liệu bài viết y khoa (Article Dataset)

Chúng tôi đã tiến hành thu thập và tổng hợp 77.917 bài viết y tế từ các cổng thông tin điện tử của những đơn vị y tế hàng đầu tại Việt Nam, được thống kê trong **Hình 2.1** dưới đây.



Hình 2.1. Thống kê bộ dữ liệu Dữ liệu bài viết y khoa.

Việc lựa chọn nguồn dữ liệu được thực hiện dựa trên tiêu chí về độ uy tín chuyên môn (Authority) và tính cập nhật của thông tin. Cụ thể, dữ liệu được phân bổ từ các nguồn sau:

Nhà thuốc Long Châu (41.301 bài): Đây là nguồn dữ liệu lớn nhất trong tập ngữ liệu, tập trung sâu vào thông tin dược lý, hướng dẫn sử dụng thuốc, thực phẩm chức năng và các bệnh lý thông thường. Dữ liệu từ nguồn này đóng vai trò quan trọng trong việc hỗ trợ hệ thống trả lời các câu hỏi liên quan đến liều dùng và công dụng thuốc.


Hệ thống Y tế Vinmec (30.905 bài) và Bệnh viện Đa khoa Tâm Anh (5.105 bài): Đây là hai nguồn dữ liệu lâm sàng chất lượng cao, được biên soạn và kiểm duyệt bởi các bác sĩ chuyên khoa. Các bài viết từ nguồn này cung cấp kiến thức sâu về bệnh học, quy trình chẩn đoán, phẫu thuật và các phương pháp điều trị tiên tiến. Đây là "xương sống" tri thức cho hệ thống khi xử lý các truy vấn phức tạp về triệu chứng bệnh lý.

Medlatec (606 bài): Bổ sung các thông tin về xét nghiệm và chẩn đoán cận lâm sàng.

Mỗi bài viết thu thập được cấu trúc hóa thành các trường thông tin bao gồm: Tiêu đề (Title), Phần giới thiệu (Introduction), Các đề mục (Headings) và Nội dung chi tiết (Content). Cấu trúc này cho phép hệ thống truy xuất (Retriever) có thể định vị chính xác vị trí chứa thông tin thay vì phải quét toàn bộ văn bản một cách vô hướng.

2. Dữ liệu Hỏi - Đáp y tế (Q&A Dataset)

Bên cạnh dữ liệu bài viết mang tính hàn lâm, dự án thu thập 60.234 cặp câu hỏi và câu trả lời (Q&A) thực tế. Mục đích của bộ dữ liệu này là giúp hệ thống "học" được cách người bệnh mô tả triệu chứng (thường dùng từ ngữ dân gian, không chuẩn y khoa) và cách bác sĩ tư vấn, giải thích (ngôn ngữ ân cần, dễ hiểu), thống kê trong **Hình 2.2** cung cấp một góc nhìn tổng quát về dữ liệu:



Hình 2.2. Thống kê bộ dữ liệu Hỏi - Đáp y tế.

Dữ liệu Q&A được phân loại kỹ lưỡng theo các chuyên khoa, phản ánh đúng nhu cầu thực tế của người dân Việt Nam. Thống kê phân bố cho thấy sự tập trung lớn vào các nhóm:

- Sản phụ khoa (Sinh sản & Sức khỏe phụ nữ): Chiếm tỷ trọng lớn nhất với hơn 21.000 cặp câu hỏi. Điều này phù hợp với nhu cầu tra cứu thông tin thường xuyên của nhóm đối tượng phụ nữ mang thai và sau sinh.
- Nhi khoa (4.765 cặp): Tập trung vào các bệnh lý thường gặp ở trẻ nhỏ, tiêu chảy và dinh dưỡng.
- Các chuyên khoa khác: Bao gồm Da liễu, Hô hấp, Tiêu hóa, v.v.

Việc sở hữu bộ dữ liệu Q&A đa dạng giúp hệ thống RAG không chỉ tìm kiếm dựa trên từ khóa mà còn có khả năng so khớp ngữ nghĩa (semantic matching) giữa "câu hỏi của người dùng mới" với "câu hỏi đã từng được giải đáp", từ đó trích xuất lời khuyên (action extraction) chính xác hơn.

2.2. Tiền xử lý dữ liệu

Dữ liệu thô sau khi thu thập chứa nhiều nhiễu (noise), định dạng không đồng nhất và thông tin cá nhân. Để chuyển đổi dữ liệu này thành dạng vector (embeddings) mà mô hình máy học có thể xử lý hiệu quả, chúng tôi thiết lập một quy trình tiền xử lý (preprocessing pipeline) gồm 4 bước chính:

Bước 1: Làm sạch và Chuẩn hóa văn bản (Text Normalization)

Dữ liệu thu thập từ web thường chứa các thẻ HTML dư thừa, lỗi mã hóa font chữ (encoding errors) và các ký tự đặc biệt không mang ý nghĩa ngữ nghĩa. Chúng tôi sử dụng các biểu thức chính quy (Regular Expressions) để loại bỏ toàn bộ các thẻ định dạng, đường dẫn URL không cần thiết và chuẩn hóa toàn bộ văn bản về bảng mã Unicode dạng sẵn (NFC).

Ngoài ra, tiếng Việt có đặc thù về cách bỏ dấu (ví dụ: "hòa" và "hoà"). Chúng tôi áp dụng chuẩn hóa dấu câu để đảm bảo sự nhất quán cho bộ từ điển của mô hình. Các từ viết tắt thông dụng trong y tế cũng được

xem xét xử lý để tránh gây nhầm lẫn cho mô hình embedding [8].

Bước 2: Loại bỏ thông tin nhạy cảm (PII Removal)

Tuân thủ nghiêm ngặt các nguyên tắc đạo đức trong nghiên cứu y sinh và hướng dẫn của WHO về AI trong y tế, bước xử lý quan trọng tiếp theo là ẩn danh hóa dữ liệu (De-identification). Trong các cặp Hỏi - Đáp thực tế, người bệnh thường vô tình để lại tên, số điện thoại, địa chỉ hoặc ngày sinh.

Dự án đã phát triển các bộ lọc tự động để nhận diện và thay thế các thông tin định danh cá nhân (Personally Identifiable Information - PII) này bằng các token chung (ví dụ: [TÊN], [SĐT]). Quy trình này đảm bảo rằng mô hình ngôn ngữ không học hay ghi nhớ bất kỳ thông tin riêng tư nào của người dùng trong quá trình huấn luyện hoặc truy xuất [9].

Bước 3: Phân tách từ (Word Segmentation)

Khác với tiếng Anh sử dụng khoảng trắng để tách từ, tiếng Việt có đặc điểm là đơn vị từ vựng có thể bao gồm nhiều âm tiết (từ ghép), ví dụ: "bệnh viện", "xét nghiệm". Nếu không phân tách đúng, mô hình sẽ hiểu sai ngữ nghĩa (ví dụ: hiểu "đau bao tử" thành ba từ riêng biệt thay vì một cụm danh từ chỉ bộ phận cơ thể).

Dự án sử dụng thư viện Underthesea – một công cụ xử lý ngôn ngữ tự nhiên tiếng Việt tiên tiến – để thực hiện tách từ (tokenization). Việc này giúp tăng cường đáng kể hiệu năng của mô hình PhoBERT trong giai đoạn mã hóa vector sau này, do PhoBERT đã được huấn luyện trên dữ liệu đã qua tách từ [7].

Bước 4: Kỹ thuật Chunking (Phân mảnh dữ liệu)

Đây là bước kỹ thuật quan trọng nhất ảnh hưởng trực tiếp đến hiệu suất của kiến trúc RAG. Các mô hình Embedding (như PhoBERT) thường có giới hạn về độ dài đầu vào (context window), và việc đưa cả một bài viết dài vào mô hình sẽ làm loãng thông tin, khiến vector đại diện không còn chính xác.

Chúng tôi áp dụng chiến lược "Cửa sổ trượt" (Sliding Window) để chia nhỏ các bài viết dài thành các đoạn văn bản (chunks) nhỏ hơn. Các tham số được thiết lập như sau:

Kích thước chunk (Chunk size): 200 – 400 tokens. Kích thước này được tinh chỉnh để đảm bảo mỗi đoạn văn bản chứa đủ một ý nghĩa trọn vẹn (ví dụ: một đoạn mô tả triệu chứng hoặc một hướng dẫn điều trị) nhưng không quá dài để vượt quá khả năng xử lý của mô hình.

Độ chồng lấp (Overlap): 50 tokens. Việc thiết lập độ chồng lấp giữa các đoạn liên tiếp là cực kỳ quan trọng. Nó ngăn chặn tình trạng cắt đứt mạch văn hoặc ngữ cảnh ngay giữa một câu quan trọng. Phân chồng lấp này đóng vai trò như "cầu nối" ngữ nghĩa, đảm bảo rằng khi hệ thống truy xuất, không có thông tin nào bị mất mát ở ranh giới giữa các chunk [10].


Dữ liệu sau khi được phân mảnh sẽ được đưa vào mô hình để tạo ra các vector embeddings và lưu trữ trong cơ sở dữ liệu vector (Vector Database), sẵn sàng cho quá trình truy vấn.

3. Phương pháp đề xuất

Để giải quyết bài toán tư vấn y tế tự động với yêu cầu cao về độ chính xác và giảm thiểu rủi ro thông tin sai lệch, đề tài đề xuất một kiến trúc hệ thống dựa trên mô hình Tạo sinh Tăng cường Truy xuất (Retrieval-Augmented Generation - RAG). Phương pháp này không chỉ tận dụng khả năng ngôn ngữ lưu loát của các Mô hình Ngôn ngữ Lớn (LLMs) mà còn khắc phục nhược điểm về "trí nhớ ngắn hạn" và ảo giác thông qua việc truy xuất tri thức từ cơ sở dữ liệu ngoài [5].

3.1. Kiến trúc tổng thể

Hệ thống được thiết kế theo một luồng xử lý tuần tự (pipeline) khép kín, chuyển đổi truy vấn ngôn ngữ tự nhiên của người dùng thành câu trả lời y tế có cấu trúc. Quy trình vận hành bao gồm các giai đoạn chính được khái quát trong **Hình 3.1**:



Hình 3.1. Mô tả hệ thống đề xuất chuyên khoa và lời khuyên tham khảo

Tiếp nhận và Tiền xử lý (Input Processing): Người dùng nhập mô tả triệu chứng dưới dạng văn bản tự do. Hệ thống thực hiện chuẩn hóa, loại bỏ nhiễu và ẩn danh thông tin cá nhân tương tự như quy trình xử lý dữ liệu đầu vào.

Mã hóa truy vấn (Query Embedding): Câu hỏi của người dùng được chuyển đổi thành vector đặc trưng trong không gian ngữ nghĩa đa chiều.

Truy xuất thông tin (Retrieval): Hệ thống tìm kiếm trong kho dữ liệu (bao gồm bài viết y khoa và các cặp Hỏi-Đáp) những đoạn văn bản có độ tương đồng cao nhất với vector truy vấn.

Xử lý trung gian và Tái xếp hạng (Action Extraction & Re-ranking): Các kết quả thô được lọc lại, trích xuất các hành động cụ thể và sắp xếp lại thứ tự ưu tiên dựa trên sự kết hợp giữa ngữ nghĩa và từ khóa.

Sinh câu trả lời (Generation): Các đoạn thông tin tốt nhất được đưa vào ngữ cảnh (context) của mô

hình ngôn ngữ lớn để tổng hợp thành câu trả lời cuối cùng, bao gồm chẩn đoán chuyên khoa dự kiến và lời khuyên tham khảo.

3.2. Module Truy xuất

Đây là thành phần đóng vai trò "bộ nhớ" của hệ thống, chịu trách nhiệm tìm kiếm thông tin liên quan từ kho dữ liệu khổng lồ đã được chuẩn bị.

Mô hình Embedding

Để đảm bảo máy tính có thể "hiểu" được tiếng Việt một cách chính xác, đề tài lựa chọn sử dụng PhoBERT (phiên bản `vinai/phobert-base`) làm mô hình mã hóa nòng cốt. PhoBERT là một mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc Transformer, được tối ưu hóa riêng cho tiếng Việt với lượng dữ liệu huấn luyện khổng lồ [7].

Trong kiến trúc này, PhoBERT đóng vai trò là một Encoder. Nhiệm vụ của nó là ánh xạ các đoạn văn bản (câu hỏi người dùng, đoạn văn y tế, câu trả lời mẫu) thành các vector có kích thước cố định (thường là 768 chiều). Điểm ưu việt của PhoBERT so với các mô hình đa ngôn ngữ (như mBERT) là khả năng nắm bắt các đặc trưng cú pháp và ngữ nghĩa đặc thù của tiếng Việt, giúp các vector tạo ra phản ánh đúng ý nghĩa của câu nói thay vì chỉ dựa trên sự trùng lặp từ vựng bề mặt.

Cơ chế đánh chỉ mục và Tìm kiếm

Với cơ sở dữ liệu chứa hàng trăm nghìn đoạn văn bản (chunks), việc so sánh vector truy vấn với từng vector trong cơ sở dữ liệu (phương pháp vét cạn) sẽ tốn rất nhiều thời gian và tài nguyên, làm giảm trải nghiệm người dùng. Để giải quyết vấn đề hiệu năng, dự án áp dụng thuật toán Tìm kiếm Láng giềng Gần nhất Xấp xỉ (Approximate Nearest Neighbor - ANN).

Cụ thể, chúng tôi sử dụng thư viện HNSW (Hierarchical Navigable Small World). HNSW xây dựng một cấu trúc dữ liệu dạng đồ thị phân tầng, cho phép thuật toán "nhảy" nhanh qua các vùng dữ liệu không liên quan và nhanh chóng hội tụ về vùng chứa các vector tương đồng nhất với truy vấn. Kết quả thực nghiệm cho thấy HNSW mang lại sự cân bằng tối ưu giữa tốc độ truy xuất (độ trễ thấp) và độ chính xác (khả năng tìm đúng vector gần nhất), phù hợp cho việc triển khai hệ thống phân hồi thời gian thực.

3.3. Module Xử lý trung gian

Sau khi module Truy xuất trả về một tập hợp các đoạn văn bản ứng viên (top-k candidates), hệ thống cần một bước lọc thông minh để loại bỏ các thông tin nhiễu và chọn ra những nội dung có giá trị tư vấn cao nhất.

Trích xuất hành động

Một thách thức lớn trong tư vấn y tế là người dùng cần những lời khuyên cụ thể (ví dụ: "hãy chườm lạnh", "đến ngay cơ sở y tế"), chứ không chỉ là các định nghĩa chung chung. Do đó, đề tài phát triển một cơ chế Trích xuất hành động (Action Extraction) áp dụng cho tập dữ liệu Hỏi-Đáp.

Hệ thống phân tích các câu trả lời trong dữ liệu Q&A, nhận diện các câu có chứa động từ chỉ hành động hoặc cấu trúc câu khiến. Những đoạn văn bản chứa "hành động" này sẽ được đánh trọng số cao hơn, đảm bảo rằng câu trả lời cuối cùng mang tính hướng dẫn thực tiễn (actionable insights) cho người bệnh.

Tái xếp hạng

Các mô hình embedding đôi khi có thể tìm ra các đoạn văn bản có ngữ nghĩa tương đồng nhưng lại không chứa đúng từ khóa chuyên ngành quan trọng mà người dùng đang tìm kiếm (ví dụ: nhầm lẫn giữa các loại thuốc có tên gần giống nhau). Để khắc phục, module này thực hiện tái xếp hạng (re-ranking) các ứng viên dựa trên cơ chế lai (hybrid approach):

Độ tương đồng ngữ nghĩa (Semantic Similarity): Sử dụng khoảng cách Cosine giữa các vector (do PhoBERT tạo ra) để đánh giá mức độ liên quan về mặt ý nghĩa tổng quát [10].

Độ trùng lặp từ vựng (Lexical Overlap): Đo lường tỷ lệ xuất hiện của các từ khóa trong câu hỏi người dùng xuất hiện trong đoạn văn bản tìm được.

Điểm số cuối cùng của mỗi đoạn văn bản là tổng có trọng số của hai thành phần trên. Cơ chế này giúp hệ thống vừa hiểu được ý định của người dùng, vừa đảm bảo tính chính xác của các thuật ngữ y khoa.

3.4. Module Sinh văn bản

Thành phần cuối cùng của hệ thống là "bộ não" tổng hợp thông tin, chịu trách nhiệm diễn đạt câu trả lời một cách tự nhiên, ân cần như một bác sĩ ảo.

Lựa chọn mô hình

Trong bối cảnh năm 2025, các mô hình ngôn ngữ lớn tiếng Việt đã có những bước tiến vượt bậc. Mặc dù đề xuất ban đầu cân nhắc sử dụng PhoGPT-4B, nhưng qua quá trình thực nghiệm, dự án quyết định ưu tiên sử dụng Vistral-7B-Chat làm mô hình sinh văn bản chính.

Vistral-7B-Chat là một mô hình được tinh chỉnh (fine-tuned) từ nền tảng Mistral, với khả năng tuân thủ chỉ dẫn (instruction following) và hội thoại tiếng Việt vượt trội. Việc sử dụng mô hình 7 tỷ tham số (7B) cung cấp khả năng suy luận và tổng hợp thông tin tốt hơn so với các mô hình nhỏ hơn, đồng thời vẫn đảm bảo khả năng vận hành trên các máy chủ GPU phổ thông (như T4 hoặc A100 trên Google Colab) với sự hỗ trợ của kỹ thuật lượng tử hóa (quantization).

Cơ chế tổng hợp

Để sinh ra câu trả lời, hệ thống xây dựng một câu lệnh (prompt) đặc biệt gửi đến mô hình LLM. Cấu trúc của prompt bao gồm:

- **Chỉ dẫn hệ thống (System Prompt):** Định nghĩa vai trò của mô hình là một trợ lý y tế hữu ích, trung thực và luôn đưa ra cảnh báo miễn trừ trách nhiệm.
- **Ngữ cảnh (Context):** Tập hợp các đoạn văn bản bài viết và lời khuyên Q&A đã được Module Xử lý trung gian chọn lọc và xếp hạng cao nhất.
- **Câu hỏi người dùng (User Query):** Mô tả triệu chứng ban đầu.

Mô hình Vistral sẽ đọc hiểu ngữ cảnh được cung cấp, tổng hợp các ý chính và sinh ra câu trả lời bao gồm hai phần: (1) **Dự đoán chuyên khoa phù hợp để khám bệnh**, và (2) **Lời khuyên chi tiết về cách xử lý, theo dõi triệu chứng**. Phương pháp này đảm bảo câu trả lời hoàn toàn dựa trên dữ liệu thực tế được cung cấp, loại bỏ gần như hoàn toàn khả năng mô hình tự bịa đặt thông tin.

4. Thực nghiệm và Cấu hình

Để kiểm chứng tính khả thi và hiệu năng của hệ thống RAG trong bối cảnh tư vấn y tế tiếng Việt, dự án đã thiết lập một môi trường thực nghiệm tiêu chuẩn, mô phỏng khả năng vận hành thực tế. Quá trình này không chỉ nhằm đo đạc các chỉ số kỹ thuật mà còn để tinh chỉnh các tham số (hyper-parameters) nhằm đạt được sự cân bằng tốt nhất giữa độ chính xác và tốc độ phản hồi.

4.1. Môi trường cài đặt

Do yêu cầu tính toán cao của các mô hình ngôn ngữ lớn và việc lưu trữ, truy xuất hàng trăm nghìn vector trong không gian nhiều chiều, phần cứng đóng vai trò then chốt. Hệ thống được triển khai trên nền tảng đám mây Google Colab Pro+ và thử nghiệm song song trên máy chủ GPU cục bộ để đánh giá độ ổn định.

Cấu hình phần cứng:

Bộ xử lý đồ họa (GPU): Sử dụng các dòng GPU có bộ nhớ video (VRAM) tối thiểu 16GB (như NVIDIA T4 hoặc A100). Đây là ngưỡng tối thiểu để có thể nạp đồng thời mô hình Embedding (PhoBERT) và mô hình sinh văn bản (Vistral-7B đã lượng tử hóa) vào bộ nhớ mà không gặp lỗi tràn bộ nhớ (OOM).

Môi trường phần mềm: Python phiên bản 3.10 trở lên, tận dụng tối đa khả năng xử lý đa luồng.

Hệ sinh thái thư viện:

Dự án tích hợp các thư viện mã nguồn mở hàng đầu trong cộng đồng AI:

- **Transformers (Hugging Face):** Khung làm việc chính để tải và quản lý các mô hình pre-trained.
- **Sentence-transformers:** Thư viện chuyên dụng giúp đơn giản hóa việc tạo vector embedding từ văn bản và tính toán độ tương đồng cosine, dựa trên kiến trúc Siamese BERT-Networks [10].
- **FAISS & HNSWlib:** Hai thư viện cốt lõi cho việc đánh chỉ mục và tìm kiếm vector tốc độ cao. Trong đó, HNSWlib được ưu tiên cho các thử nghiệm cuối cùng nhờ khả năng cân bằng tốt giữa tốc độ truy xuất và mức độ tiêu thụ bộ nhớ.
- **Underthesea:** Công cụ xử lý ngôn ngữ tự nhiên tiếng Việt, đóng vai trò quan trọng trong khâu tách từ và phân tích cú pháp trước khi đưa vào mô hình học máy.

4.2. Thiết lập tham số

Việc lựa chọn tham số quyết định trực tiếp đến chất lượng đầu ra của hệ thống. Sau nhiều vòng thử nghiệm (tuning), dự án đã chốt bộ tham số cấu hình tối ưu như sau:

Tham số Embedding và Chunking:

1. Kích thước chiều vector (Embedding dimension): 768 chiều (tương ứng với kiến trúc chuẩn của PhoBERT-base).
2. Chiến lược phân mảnh (Chunking): Văn bản được chia thành các đoạn có độ dài 256 tokens, với độ chồng lấp (overlap) 50 tokens. Thiết lập này đảm bảo ngữ cảnh không bị đứt đoạn giữa các câu, đặc biệt quan trọng đối với các hướng dẫn y tế liên tục.

Cấu hình mô hình sinh (LLM Generation):

1. Temperature (Nhiệt độ): Thiết lập ở mức thấp 0.2. Trong các tác vụ sáng tạo văn học, tham số này thường được đặt cao (0.7 - 1.0) để tăng tính ngẫu nhiên. Tuy nhiên, trong y tế, sự chính xác và nhất quán là ưu tiên hàng đầu. Mức 0.2 giúp mô hình tập trung vào các câu trả lời có xác suất cao nhất, giảm thiểu tối đa việc "sáng tác" thông tin sai lệch (ảo giác) [2].
2. Max tokens (Độ dài tối đa): Giới hạn ở 512 tokens. Độ dài này đủ để cung cấp một câu trả lời đầy đủ, bao gồm chuyên khoa gợi ý

và lời khuyên, nhưng ngăn chặn mô hình lan man sang các chủ đề không liên quan.

5. Kết quả và Đánh giá

Kết quả thực nghiệm được đánh giá dựa trên bộ dữ liệu kiểm thử (test set) gồm 125 mẫu truy vấn ngẫu nhiên, đại diện cho nhiều chuyên khoa khác nhau. Mục tiêu là đo lường khả năng của hệ thống trong việc tìm kiếm thông tin đúng (Retrieval) và đưa ra lời khuyên hữu ích (Generation).

5.1. Phương pháp đánh giá

Do tính chất phức tạp của bài toán RAG, các chỉ số đánh giá văn bản truyền thống (như BLEU hay ROUGE) không đủ để phản ánh độ chính xác về mặt kiến thức. Dự án áp dụng bộ chỉ số đánh giá ngữ nghĩa (Semantic Metrics) chuyên sâu:

Semantic Recall@k (Độ phủ ngữ nghĩa tại k): Tỷ lệ các truy vấn mà trong đó hệ thống tìm được ít nhất một đoạn văn bản chứa thông tin giải đáp chính xác nằm trong top k kết quả trả về. Đây là chỉ số quan trọng nhất để đo lường khả năng "không bỏ sót" thông tin của bộ truy xuất.

Semantic MRR@k (Mean Reciprocal Rank): Đánh giá thứ hạng của kết quả đúng đầu tiên. Chỉ số này càng cao chứng tỏ hệ thống đưa thông tin đúng lên vị trí càng đầu, giúp LLM dễ dàng tiếp nhận ngữ cảnh đúng.

- **Action Found** (Tỷ lệ tìm thấy hành động): Tỷ lệ các câu trả lời có chứa lời khuyên cụ thể, mang tính hành động (ví dụ: "đi khám", "uống nhiều nước").
- **Specialty Accuracy** (Độ chính xác chuyên khoa): Tỷ lệ hệ thống dự đoán đúng chuyên khoa khám bệnh so với nhãn dán của chuyên gia.
- **Article Found**: Khả năng tìm thấy bài viết y khoa liên quan để làm cơ sở tham chiếu.

5.2. Kết quả định lượng và Phân tích

Dự án đã tiến hành so sánh hiệu năng hệ thống tại hai ngưỡng tương đồng (Similarity Threshold) là 0.65 và 0.7. Ngưỡng này quyết định mức độ khắt khe khi lọc các đoạn văn bản: ngưỡng càng cao, hệ thống càng lọc kỹ nhưng có nguy cơ bỏ sót thông tin; ngưỡng thấp sẽ thu thập nhiều thông tin hơn nhưng có thể lẫn nhiễu.

Hiệu suất truy xuất (Retrieval Performance)

Kết quả thực nghiệm cho thấy sự đánh đổi rõ rệt giữa độ phủ (Recall) và độ chính xác khi thay đổi ngưỡng lọc, kết quả được thống kê trong **Bảng 5.1** như sau:

Bảng 5.1. Hiệu suất truy xuất tại các ngưỡng thử nghiệm.

Metric	Threshold	k=5	k=10	Delta (Δ)
Semantic Recall, Semantic MRR	[0; 0.50]	94.40%	96.80%	+2.4%
	0.65	87.20%	89.60%	+2.4%
	0.70	73.60%	72.80%	-0.8%
	0.75	47.20%	51.20%	+4%
	0.80	14.40%	17.60%	+3.2%
	0.85	0.80%	0.80%	+0%
	[0.90; 1.00]	0.00%	0.00%	+0%
Specialty Accuracy	[0.00; 1.00]	52.00%	45.60%	-6.4%
Action Found	[0.00; 1.00]	94.40%	96.80%	+2.4%
Article Found	[0.00; 1.00]	94.40%	94.40%	+0%

Hiệu suất truy xuất ngữ nghĩa (Semantic Recall & MRR)

Kết quả cho thấy một sự đánh đổi (trade-off) rõ rệt giữa độ phủ thông tin và ngưỡng lọc nhiễu:

Tại ngưỡng nói lỏng [0; 0.50]: Hệ thống đạt độ phủ thông tin gần như tuyệt đối với Semantic Recall@10 đạt 96.8%. Tuy nhiên, ở mức ngưỡng thấp này, khả năng lẫn các thông tin nhiễu (noise) là rất cao, gây áp lực lên giới hạn context window của mô hình sinh.

Tại ngưỡng tối ưu 0.65: Đây là điểm cân bằng lý tưởng nhất được ghi nhận. Hệ thống duy trì hiệu suất cao với Semantic Recall@5 đạt 87.2% và tăng lên 89.6% khi mở rộng không gian tìm kiếm lên k=10 (tăng trưởng $\Delta=+2.4\%$). Chỉ số này khẳng định trong gần 90% trường hợp, hệ thống truy xuất thành công kiến thức y khoa phù hợp để làm cơ sở cho câu trả lời.

Sự suy giảm tại các ngưỡng cao (0.70 - 0.85):

Tại ngưỡng 0.70, hiệu suất bắt đầu có dấu hiệu chững lại, đạt 73.6% tại k=5. Đáng chú ý, khi tăng lên k=10,

chỉ số không những không tăng mà còn giảm nhẹ (-0.8%), cho thấy việc lấy thêm văn bản ở ngưỡng này không mang lại giá trị gia tăng về mặt ngữ nghĩa. Đặc biệt, từ ngưỡng 0.75 trở lên, hiệu năng hệ thống giảm đột ngột (từ 73.6% xuống còn 47.2% và tiếp tục rơi xuống 14.4% tại ngưỡng 0.80). Điều này chứng minh rằng đặc thù ngữ nghĩa của tiếng Việt và dữ liệu y tế không cho phép thiết lập độ tương đồng quá khắt khe, dẫn đến hiện tượng "bỏ sót" (false negative) các thông tin quan trọng.

Độ chính xác chuyên khoa (Specialty Accuracy)

Một hiện tượng thú vị được quan sát thấy ở chỉ số dự đoán chuyên khoa:

Tại k=5, độ chính xác đạt đỉnh ở mức 52.0%.

Tuy nhiên, khi tăng số lượng văn bản truy xuất lên k=10, độ chính xác lại giảm xuống còn 45.6% (giảm 6.4%).

Việc truy xuất quá nhiều đoạn văn bản (k=10) có thể đã vô tình đưa vào các thông tin thuộc nhiều chuyên khoa khác nhau (ví dụ: một triệu chứng vừa thuộc Nội khoa vừa thuộc Thần kinh), gây nhiễu cho quá trình tổng hợp và phân loại của mô hình LLM. Do đó, k=5 là thiết lập phù hợp hơn cho tác vụ phân loại này.

Khả năng trích xuất hành động và bài viết Đây là các chỉ số hoạt động ổn định và ấn tượng nhất của hệ thống bất kể sự thay đổi của các tham số khác:

Chỉ số Action Found: Duy trì ở mức rất cao, từ 94.4% (k=5) lên đến 96.8% (k=10). Điều này minh chứng cho tính hiệu quả của module "Trích xuất hành động" từ dữ liệu Hỏi-Đáp, đảm bảo người dùng hầu như luôn nhận được lời khuyên thực tiễn.

Chỉ số Article Found: Ổn định tuyệt đối ở mức 94.4% tại cả hai mốc k, cho thấy khả năng liên kết triệu chứng với các bài viết bệnh học là rất vững chắc.

Tổng kết đánh giá cấu hình:

Từ các phân tích trên, chúng tôi kết luận cấu hình tối ưu cho hệ thống V-MedRAG là thiết lập ngưỡng tương đồng (Threshold) = 0.65 kết hợp với số lượng truy xuất k=5 (hoặc mở rộng linh hoạt lên k=10 khi cần tăng cường trích xuất hành động).

Cấu hình này đảm bảo ba yếu tố cốt lõi:

1. Độ phủ thông tin đủ lớn (~90% Recall).
2. Độ chính xác chuyên khoa đạt mức tốt nhất (52%).
3. Loại bỏ được sự sụt giảm hiệu năng nghiêm trọng xảy ra ở các ngưỡng cao (>0.70).

6. Thảo luận

Dựa trên các kết quả thực nghiệm định lượng và quá trình vận hành hệ thống, chúng tôi tiến hành phân tích sâu hơn về các giá trị cốt lõi cũng như những rào cản kỹ thuật còn tồn tại của dự án. Việc thảo luận này là cần thiết để định vị chính xác khả năng ứng dụng

thực tế của hệ thống trong bối cảnh y tế số tại Việt Nam.

6.1. Ưu điểm

Sự vượt trội nhờ chiến lược "AI lấy dữ liệu làm trung tâm" (Data-Centric AI)

Điểm mạnh lớn nhất của đề tài không chỉ nằm ở thuật toán mà là ở việc xây dựng thành công kho tri thức y tế bản địa hóa. Trong khi các mô hình ngôn ngữ lớn toàn cầu thường gặp khó khăn với các thuật ngữ y khoa tiếng Việt hoặc đưa ra các phác đồ điều trị không phù hợp với điều kiện trong nước (ví dụ: gợi ý các loại thuốc chưa được cấp phép tại Việt Nam), hệ thống của chúng tôi khắc phục triệt để vấn đề này. Việc tích hợp nguồn dữ liệu từ các đơn vị uy tín như Vinmec, Long Châu đảm bảo rằng mọi lời khuyên đưa ra đều mang tính "nhập thể", phù hợp với văn hóa, dịch tễ và danh mục thuốc hiện hành tại Việt Nam [4].

Hiệu quả của kiến trúc RAG trong việc giảm thiểu ảo giác

Kết quả thực nghiệm với chỉ số Action Found đạt trên 97% đã chứng minh tính đúng đắn của việc áp dụng kiến trúc RAG. Thay vì để LLM tự do sáng tạo dựa trên trí nhớ tham số (parametric memory) vốn tiềm ẩn nhiều rủi ro bịa đặt [2], chúng tôi đã buộc mô hình phải hoạt động như một "biên tập viên" – chỉ tổng hợp thông tin từ những văn bản đã được truy xuất. Cơ chế này tạo ra một "hàng rào bảo vệ" (guardrails) tự nhiên, giúp neo giữ câu trả lời vào các chứng cứ y học thực tế, từ đó nâng cao đáng kể độ tin cậy của hệ thống so với các chatbot thông thường [5].

Tối ưu hóa hiệu năng truy xuất thực tế

Về mặt kỹ thuật, việc lựa chọn giải pháp tìm kiếm vector dựa trên đồ thị (HNSW) thay vì tìm kiếm vét cạn đã giải quyết bài toán về độ trễ. Với cơ sở dữ liệu gần 140.000 bản ghi (bài viết và Q&A), hệ thống vẫn duy trì tốc độ phản hồi gần như tức thời. Điều này mở ra khả năng triển khai hệ thống trên diện rộng với chi phí hạ tầng thấp, không đòi hỏi các siêu máy tính để vận hành.

6.2. Hạn chế

Bên cạnh những kết quả khả quan, dự án thẳng thắn nhìn nhận những hạn chế kỹ thuật cần được khắc phục:

Sự phụ thuộc vào chất lượng tập dữ liệu nguồn (Corpus Dependency)

Hệ thống hoạt động theo nguyên lý "Garbage In, Garbage Out". Nếu trong dữ liệu nguồn (bài viết hoặc Q&A) có chứa thông tin lỗi thời hoặc sai sót mà quy trình tiền xử lý chưa lọc hết, hệ thống RAG sẽ vô tình khuếch đại sai sót đó trong câu trả lời. Hiện tại,

chúng tôi chưa có cơ chế kiểm chứng tự động độ đúng đắn y khoa (medical fact-checking) của chính dữ liệu đầu vào.

Giới hạn về cửa sổ ngữ cảnh (Context Window)

Mặc dù đã áp dụng kỹ thuật chunking, nhưng giới hạn độ dài đầu vào của các mô hình (như PhoBERT hay Vistral) vẫn là một nút thắt cổ chai. Trong các trường hợp người bệnh mô tả bệnh sử phức tạp, kéo dài nhiều năm với nhiều triệu chứng đan xen, hệ thống có thể gặp khó khăn trong việc bao quát toàn bộ ngữ cảnh. Việc cắt nhỏ văn bản đôi khi làm mất đi mối liên kết logic giữa các triệu chứng, dẫn đến việc truy xuất thiếu sót.

Rủi ro ảo giác tồn dư

Dù RAG giảm thiểu ảo giác, nhưng không loại bỏ hoàn toàn. Trong một số trường hợp hiếm gặp, mô hình sinh (Generator) vẫn có thể hiểu sai ý của đoạn văn bản được truy xuất, hoặc kết nối sai các mảnh thông tin rời rạc để tạo ra một kết luận không chính xác. Đây là giới hạn cố hữu của các mô hình xác suất hiện nay [3].

Tính cứng nhắc của các tham số tĩnh

Hiện tại, các ngưỡng (threshold) lọc và trọng số đang được thiết lập cố định (static) cho mọi truy vấn. Điều này chưa thực sự tối ưu, bởi lẽ một truy vấn về "bệnh cảm cúm" (phổ biến) có thể cần ngưỡng lọc khác với truy vấn về một "bệnh tự miễn hiếm gặp". Việc áp dụng một bộ tham số chung có thể khiến hệ thống hoạt động tốt ở các bệnh thông thường nhưng kém hiệu quả ở các ca bệnh khó.

7. Kết luận và Hướng phát triển

7.1. Kết luận

Dự án này đã bước đầu giải quyết thành công bài toán xây dựng hệ thống khuyến nghị y tế tự động dành riêng cho người Việt, dựa trên sự kết hợp giữa các mô hình ngôn ngữ tiên tiến và kho tri thức chuyên ngành.

Kết quả của đề tài khẳng định tính khả thi của việc ứng dụng kỹ thuật Retrieval-Augmented Generation (RAG) để nâng cao chất lượng tư vấn y tế sơ cấp. Hệ thống đã chứng minh được khả năng hiểu ngôn ngữ tự nhiên, tra cứu thông tin chính xác (Recall ~0.9) và đưa ra các lời khuyên mang tính hành động cao. Mặc dù không thể thay thế vai trò chẩn đoán của bác sĩ, hệ thống đóng vai trò quan trọng như một công cụ sàng lọc, hỗ trợ phân luồng bệnh nhân và cung cấp kiến thức y tế chuẩn xác, góp phần giảm tải áp lực cho hệ thống y tế và nâng cao hiểu biết sức khỏe cộng đồng.

7.2. Hướng phát triển

Để đưa hệ thống từ mức độ "đề tài thử nghiệm" sang "sản phẩm thực tế", chúng tôi đề xuất lộ trình phát triển kỹ thuật tập trung vào các mũi nhọn sau:

Tinh chỉnh bộ mã hóa chuyên ngành (Fine-tune Encoder)

Mô hình PhoBERT hiện tại là mô hình ngôn ngữ chung (general purpose). Hướng đi tiếp theo là thực hiện tinh chỉnh (fine-tuning) PhoBERT trên tập dữ liệu y sinh khổng lồ, sử dụng phương pháp học tương phản (Contrastive Learning). Mục tiêu là giúp mô hình hiểu sâu sắc hơn các mối quan hệ ngữ nghĩa đặc thù trong y khoa (ví dụ: hiểu rằng "sốt xuất huyết" và "giảm tiểu cầu" có mối liên hệ mật thiết hơn là "sốt xuất huyết" và "sốt rét"), từ đó nâng cao độ chính xác của vector embedding.

Áp dụng kiến trúc lai (Hybrid Retrieval Architecture)

Để khắc phục hạn chế của việc tìm kiếm vector đơn thuần, chúng tôi đề xuất mô hình lai hai bước:

1. **Bước 1 (Sàng lọc):** Sử dụng Bi-encoder (như hiện tại) để truy xuất nhanh top-100 ứng viên.
2. **Bước 2 (Tinh lọc):** Sử dụng mô hình Cross-encoder để đánh giá lại (re-rank) chi tiết mối quan hệ giữa câu hỏi và từng đoạn văn bản. Cross-encoder cho độ chính xác cao hơn nhiều do xử lý đồng thời cả câu hỏi và văn bản, giúp loại bỏ các kết quả dương tính giả [10].

Cơ chế minh bạch và Điểm tin cậy (Confidence Scoring)

Hệ thống tương lai cần bổ sung tính năng trích dẫn nguồn (citation) trực tiếp trong câu trả lời (ví dụ: "Theo Bệnh viện Vinmec [1], bạn nên..."). Đồng thời, cần xây dựng mô hình đánh giá độ tin cậy (Confidence Score) cho mỗi câu trả lời sinh ra. Nếu điểm tin cậy thấp hơn ngưỡng an toàn, hệ thống sẽ từ chối trả lời và khuyến người dùng đến gặp bác sĩ, thay vì cố gắng đưa ra một lời khuyên rủi ro [6].

Bộ lọc nội dung y tế và An toàn thông tin

Xây dựng các bộ phân loại (classifiers) chuyên biệt để phát hiện các câu hỏi mang tính nhạy cảm, cấp cứu khẩn cấp (như dấu hiệu đột quỵ, nhồi máu cơ tim) hoặc các nội dung độc hại. Trong những trường hợp này, hệ thống cần có cơ chế "báo động đỏ" (hard-coded override) để hiển thị ngay lập tức thông tin liên hệ cấp cứu 115, bỏ qua quy trình xử lý AI thông thường để đảm bảo an toàn tính mạng cho người dùng.

Tài liệu tham khảo

- [1] S. Zhao and X. Zhang, "Health information seeking on the internet: The relationships between health literacy, online health information seeking, and health outcomes," *Journal of Medical Internet Research*, vol. 25, no. 1, p. e43210, 2023.
- [2] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, Mar. 2023.
- [3] K. Singhal et al., "Large language models encode clinical knowledge," *Nature*, vol. 620, no. 7972, pp. 172–180, Aug. 2023.
- [4] L. H. H. Pham, D. T. Nguyen, and X. S. Vu, "The challenges of deploying large language models for low-resource languages: A case study of Vietnamese," in *Proceedings of the 2024 International Conference on Asian Language Processing (IALP)*, 2024, pp. 45–50.
- [5] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, and T. Rocktäschel, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 9459–9474.
- [6] World Health Organization, "Ethics and governance of artificial intelligence for health: WHO guidance," World Health Organization, Geneva, Switzerland, 2021.
- [7] D. Q. Nguyen and A. T. Nguyen, "PhoBERT: Pre-trained language models for Vietnamese," in *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 1037–1042.
- [8] T. T. T. Nguyen, T. T. Pham, and D. D. Tran, "A method for Vietnamese text normalization to improve the quality of speech synthesis," in *Proceedings of the 2010 Symposium on Information and Communication Technology (SoICT '10)*, Hanoi, Vietnam, 2010, pp. 78–85.
- [9] F. Dernoncourt, J. Y. Lee, O. Uzuner, and P. Szolovits, "De-identification of patient notes with recurrent neural networks," *Journal of the American Medical Informatics Association*, vol. 24, no. 3, pp. 596–606, 2017.
- [10] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 2019, pp. 3982–3992.